Übung 01

Arbeitsaufwand insgesamt: 6h

Inhaltsverzeichnis

bung 01	1
Teil 1 – Mustersuchalgorithmen	2
Lösungsidee:	2
Lösung:	2
Source-Code:	3
Testfälle	18
Teil 2 – Bacon-Index	19
Lösungsidee:	19
Lösung:	19
Source-Code:	20
Testfälle	31

Teil 1 – Mustersuchalgorithmen

Ziel dieser Übung ist die Implementierung der bereits im 2. Semester besprochenen Mustersuchalgorithmen BruteSearch, BoyerMooreSearch und KnuthMorisPrathSearch.

Lösungsidee:

Als erstes würde ich die Suchalgorithmen in gleichnamigen Klassen implementieren.

Die Algorithmen sind schnell zusammengefasst:

- BruteSearch ist ineffizient und verschiebt im Fehlerfall immer nur um ein Zeichen.
- BoyerMooreSearch verwendet eine zuvor erstellte, Muster-Spezifische Offset-Tabelle und bestimmt daraus im Fehlerfall, um wie viele Stellen verschoben werden darf. Außerdem wird das Muster von hinten nach vorne verglichen.
 - Eignet sich vor allem für lange Muster.
- KnuthMorisPrathSearch basiert auf einer Sprungtabelle, welche aufgrund der Präfixe, welche gleichzeitig auch Suffixe des bereits gematchten Musters sind, die Sprungweite im Fehlerfall bestimmt.
 - o Eignet sich vor allem für kleine Alphabete und Muster mit sich wiederholenden Teilen.

Zusätzlich dazu, würde ich die Methode "search" sowie die Hilfsmethoden überladen, sodass ein DataCollector mitgegeben werden kann. Der DataCollector enthält einfache Zählvariablen für jeden Operationstyp (bzw. eine Map, um die Buchstaben zu zählen) und zugehörige Methoden, die es einfach machen diese Werte zu inkrementieren bzw. um einen bestimmten Wert zu erhöhen. Zusätzlich dazu müssen in der abgeänderten "search" Methode auch nach jeder Operation (oder zumindest gesammelt, nach einem Block) die jeweiligen Methoden zum Zählen der Operationen aufgerufen werden.

Lösung:

Als IDEA Projekt im Archiv Nachfolgender Source-Code

Source-Code:

SearchTest.java

```
static void normalTest() {
static void emptyTest() {
static void binaryTest() {
```

```
dc1.writeToFile("datacollector/BF binary "+len+".csv");
       dc3.writeToFile("datacollector/KMP binary "+len+".csv");
static void baseTest() {
       dc1.writeToFile("datacollector/BF basepair "+len+".csv");
        dc2.writeToFile("datacollector/BM basepair "+len+".csv");
static void aminoTest() {
    DataCollector dc3 = new DataCollector();
static void asciiTest() {
    DataCollector dc1 = new DataCollector();
```

```
DataCollector dc2 = new DataCollector();
DataCollector dc3 = new DataCollector();

for(int len=10; len <= 1000; len*=10) {
    for(int i=0; i < 1000; i++) {
        String text = getRandomText(len, 2);
        String pattern = getRandomText(10,2);

        int pos1 = BruteSearch.search(text, pattern, 0, dc1);
        int pos2 = BruteSearch.search(text, pattern, 0, dc2);
        int pos3 = BruteSearch.search(text, pattern, 0, dc3);
    }
    dc1.writeToFile("datacollector/BF_ascii_"+len+".csv");
    dc2.writeToFile("datacollector/BM_ascii_"+len+".csv");
    dc3.writeToFile("datacollector/KMP_ascii_"+len+".csv");
}
</pre>
```

BruteSearch.java

```
int foundPos = -1;
pattern.charAt(pIndex) == text.charAt(pos+pIndex)) {
DataCollector dc) {
```

```
dc.logIndOp(2);
pattern.charAt(pIndex) == text.charAt(pos+pIndex)) {
        return foundPos;
```

BMSearch.java

```
Map<Character, Integer> table = makeOffsetTable(pattern);
        int foundPos = -1;
        return foundPos;
DataCollector dc) {
        int pos = pLen + offset - 1;
        int foundPos = -1;
        dc.logLogOp(5);
```

```
dc.logAddOp();
        dc.logLogOp(3);
       dc.logAddOp(3);
            dc.logCharCmp(text.charAt(pos - pIndex), false);
           dc.logIndOp();
                dc.logIndOp(); // pos
private static Map<Character, Integer> makeOffsetTable(String pattern) {
```

```
Map<Character, Integer> table = new HashMap<Character, Integer>();

for(int i=0; i < pattern.length()-1; i++) {
        table.put(pattern.charAt(i),pattern.length()-1-i);
}

return table;
}

private static Map<Character, Integer> makeOffsetTable(String pattern,
DataCollector dc) {
    Map<Character, Integer> table = new HashMap<Character, Integer>();
    dc.logAssOp();
    dc.logAssOp();
    dc.logAddOp();
    for(int i=0; i < pattern.length()-1; i++) {
        dc.logLogOp();
        dc.logAddOp();
        table.put(pattern.charAt(i),pattern.length()-1-i);
        dc.logAddOp();
        dc.logAddOp();
        dc.logAddOp();
        dc.logAddOp();
        dc.logAddOp();
        dc.logAddOp();
}

return table;
}
</pre>
```

KMPSearch.java

```
public class KMPSearch {
                dc.logIndOp(2);
                dc.logAssOp();
            dc.logCmp();
```

```
pattern.charAt(pos pattern)) {
    static int[] getLeapTbl(String pattern) {
        if(pattern.isEmpty()) {
pattern.charAt(prefixSize)) {
        return leapTbl;
    static int[] getLeapTbl(String pattern, DataCollector dc) {
        dc.logAssOp(2); // parameters
        int[] leapTbl = new int[pattern.length()];
```

```
pattern.charAt(prefixSize)) {
```

CharacterStat.java

```
package swp4.ue01.part1.DataCollection;

public class CharacterStat {
    private int totalComparisons;
    private int successfulComparisons;

public CharacterStat() {
        totalComparisons = 0;
        successfulComparisons = 0;
}

public void updateStats(boolean success) {
        totalComparisons++;
        if(success) {
            successfulComparisons++;
        }
}

public int getSuccessfulComparisons() {
        return successfulComparisons;
}

public int getFailedComparisons() {
        return totalComparisons - successfulComparisons;
}
```

DataCollector.java

```
import java.io.FileWriter;
   public DataCollector() {
   public void logCharCmp(char letter, boolean success) {
           stat.updateStats(success);
   public void logLogOp() {
   public void logAddOp() {
    public void logMultOp() {
```

```
public void logIndOp() {
    public void logCmp() {
    public void logAssOp() {
    public void logLogOp(int amount) {
    public void logAddOp(int amount) {
    public void logMultOp(int amount) {
    public void logIndOp(int amount) {
    public void logCmp(int amount) {
    public void logAssOp(int amount) {
    public void printStatistics() {
    public void writeToFile(String filename) {
        try(FileWriter fout = new FileWriter(filename)) {
fout.write(charCmp+";"+logOp+";"+addOp+";"+multOp+";"+indOp+";"+cmp+";"+assOp+
                fout.write(key+";");
charCmpTable.get(key).getSuccessfulComparisons()+";";
```

```
failLine += charCmpTable.get(key).getFailedComparisons()+";";
}
fout.write("\n");
fout.write(successLine+"\n");
fout.write(failLine+"\n");

catch(IOException e)
{
    System.out.println("Coult not write to file: " + filename);
    e.printStackTrace();
}
}
```

Testfälle

- Normale Benützung
- Leere Eingaben für Muster/Text/Beides
- Datacollector CSVs

Normale Benützung:

```
Pattern found at position 12.
Pattern found at position 12.
Pattern found at position 12.
```

Leere Eingaben:

```
Pattern found at position -1.
Pattern found at position -1.
Pattern found at position -1.
```

Die Ausgaben für die jeweiligen Alphabete, Längen und Algorithmen ist im Ordner "datacollector" im Projektordner zu finden.

Teil 2 - Bacon-Index

Anschließend zu Beispiel 1 soll noch das Wissen aus der Übung eingesetzt werden, um einen Graph aus Schauspielern/Filmen aufzubauen und mithilfe von diesem den sogenannten Bacon-Index zu berechnen. Der Kevin-Bacon Index sagt aus, über "wie viele Filme" die Verbindung dieser Schauspieler verläuft.

Lösungsidee:

Ursprünglich wollte ich dieses Beispiel mithilfe einer Adjazenzmatrix lösen (Dreiecksmatrix mit ArrayLists), jedoch war die Datenmenge zu groß für den Heap. Im Retrospekt macht eine Adjazenzliste auch mehr Sinn, da das Verhältnis von Knoten zu Kanten zu gering ist (viele "unnütze" "false" Werte in der Matrix).

Bei der Berechnung des Bacon-Index wird mit einem der beiden Akteure gestartet und von diesem aus alle Nachbarn bestimmt (= genau EIN Film Distanz). Dieser Prozess wird dann für die erhaltenen Akteure wiederholt, bis sich die Zielperson unter den Akteuren befindet oder alle Knoten durchsucht wurden.

Um Performanz zu verbessern (und um vertretbare Suchzeiten zu erhalten) musste ich zusätzlich mehreren Caching-Algorithmen mittels Maps und ArrayLists arbeiten. Ein Beispiel dafür wäre, die Bereiche der Filme (Start- und Endindex in der Adjazenzliste) festzuhalten, damit später bei der Suche nach Film-Zuweisungen nur bedeutend geringere Bereiche durchsucht werden müssen.

Lösung:

Als Java Projekt im Archiv Nachfolgender Source-Code

Source-Code:

MovieTest.java

```
while(!name1.isEmpty() && !name2.isEmpty()) {
                name2 = readInputFromSystemIn();
            if(!name1.isEmpty() && !name2.isEmpty()) {
public static String readInputFromSystemIn() throws Exception {
   return reader.readLine();
```

Graph.java

```
package swp4.ue01.part2.collections.graph;
public interface Graph {
   boolean addEdge( int src, int dest );
   boolean removeEdge( int src, int dest );
   boolean hasEdge( int src, int dest );
}
```

MovieGraph.java

```
import swp4.ue01.part2.calculation.BaconIndexCalculator;
   private MovieSymbolTable mst;
        try (BufferedReader bReader = new BufferedReader(new
InputStreamReader(new FileInputStream(filename)))) {
           String line;
            int entryNum = 0;
                            movieNum = mst.size()-1;
```

```
addEdge(mst.size()-1, movieNum);
                            entryNum++;
                            entryNum++;
            e.printStackTrace();
        System.out.println("Successfully created graph for "+filename+".");
        if(mst.isMovie(src)) {
    public boolean removeEdge(int src, int dest) {
            return adjacencyList.remove(new
            return adjacencyList.remove(new
AbstractMap.SimpleEntry(dest,src));
    public boolean hasEdge(int src, int dest) {
```

```
if (mst.isMovie(dest)) {
    public ArrayList<Integer> getConnectedActors(int index, ArrayList<Integer>
        ArrayList<Integer> values = new ArrayList();
        ArrayList<Integer> allMovies = mst.getMovies();
            if (hasEdge (index, movieIdx, mstart, mend)
&& !scanned.contains(movieIdx)) {
                scanned.add(movieIdx);
```

```
scanned.add(index);
}

// finally return the arraylist
    return values;
}

// returns the Bacon-Index for the given actors
public int getBaconIndex(String name1, String name2) {
    return BaconIndexCalculator.calculateBaconIndex(this, this.mst, name1,
name2);
}

public void testRandomBacons() {
    // random actors to check if bacon-index seems feasible
    Random rand = new Random();
    for(int i=0; i < 1000; i++) { // Try for 1000 random pairs
        int p1 = 1;//rand.nextInt(mst.size());
        int p2 = 2;//rand.nextInt(mst.size());

        if(mst.isActor(p1) && mst.isActor(p2)) {
            System.out.println("'"+mst.getValue(p1)+"' and
'""+mst.getValue(p2)+"':"+BaconIndexCalculator.calculateBaconIndex(this, mst, mst.getValue(p1), mst.getValue(p2)));
        }
    }
}</pre>
```

MovieNode.java

```
package swp4.ue01.part2.collections;

public class MovieNode {
    private String value;
    private boolean movie;

    // create a movienode
    public MovieNode(String value, boolean movie) {
        this.value = value;
        this.movie = movie;
    }

    // return the nodes value
    public String getValue() {
        return value;
    }
    // return whether the node is a movie or not
    public boolean isMovie() {
        return movie;
    }
}
```

MovieSymbolTable.java

```
import java.util.ArrayList;
   public MovieSymbolTable() {
           movieIdx.add(nodeId);
   public String getValue(int nodeId) {
    public int size() {
```

```
return nodes.size();
}

// returns a list of all movie indices
public ArrayList<Integer> getMovies() {
    return movieIdx;
}
```

BaconIndexCalculator.java

```
import swp4.ue01.part2.collections.MovieSymbolTable;
mst, String name1, String name2) {
mst.isMovie(mst.getIndex(name1)) || mst.isMovie(mst.getIndex(name2))) {
        actors.add(mst.getIndex(name1));
graph.getConnectedActors(idx, scanned);
                    tmpNbList.forEach(actors::add);
```

Testfälle

- Eingabe in der Konsole
- Gleiche Person
- Nichtexistente Akteure
- Bacon-Index von Filmen
- Leeres File
- Abbruch
- Zufällige Personen

Eingabe in der Konsole:

Successfully created graph for movies.txt.

Press enter without content to exit.

Please enter the first actors name:

Tygner, Robert

Please enter the second actors name:

White, Miranda

Their bacon-index is: 3

Gleiche Person:

Successfully created graph for movies.txt.

Press enter without content to exit.

Please enter the first actors name:

White, Miranda

Please enter the second actors name:

White, Miranda

This is the same person!

Their bacon-index is: 0

Leeres File:

Successfully created graph for empty.txt.

Press enter without content to exit.

Please enter the first actors name:

Williams, Robin

Please enter the second actors name:

Cena, John

Couldn't calculate Bacon index, since the given names couldn't be found!

Their bacon-index is: -1

Abbruch:

Successfully created graph for empty.txt.

Press enter without content to exit.

Please enter the first actors name:

Enter detected. Exiting...

Nichtexistente Akteure:

```
Successfully created graph for movies.txt.

Press enter without content to exit.

Please enter the first actors name:

Johannes

Please enter the second actors name:

Merkel

Couldn't calculate Bacon index, since the given names couldn't be found!

Their bacon-index is: -1
```

Bacon-Index von Filmen:

```
Successfully created graph for movies.txt.

Press enter without content to exit.

Please enter the first actors name:

'Breaker' Morant (1980)

Please enter the second actors name:

'Crocodile' Dundee II (1988)

Couldn't calculate Bacon index, since the given names couldn't be found!

Their bacon-index is: -1
```

Zufällige Akteure:

```
'Muska, Vaclav' and 'Kadani, Otis':4

'McClain, Johnathan (II)' and 'Roussel, Francine':3

'Barbour, Joyce' and 'Dong, Pu Ye':5

'von Dohlen, Lenny' and 'McGraw, Kathy':3

'Hewson, Thomas' and 'Carr, Ben (I)':3

'Garcia, Jon (I)' and 'Szanyi, Monica':2

'Taggart, Rachel' and 'Goryl, Dave':4

'Sinatra Jr., Frank' and 'Davis, Cherry (I)':3

'Rodriguez, Lucy' and 'Reiner, Richie':3

'Brimley, Wilford' and 'Davies, Erik':2

'Cromwell, J.T.' and 'Buchette, Oliver':5

'Alvarez, Dale' and 'Carver, Mary':3

'Gómez, Paz' and 'Yankovsky, Filipp':4

'Wilson, Hal (I)' and 'Daquila, Lawrence':3

'Brown, Bryan (I)' and 'Henderson, Dick (II)':1
```